


Credit Risk Prediction Model Using Machine Learning

ID/X Partners - Data Scientist

Presented by
Agil Firli Gunawan





Agil Firli Gunawan

Information Systems Undergraduate | Data Analyst ,
Business Intelligence , Data Science Enthusiast

About Me

Mahasiswa Semester 7 Sistem Informasi dengan minat pada Data Analyst, Business Intelligence, dan Data Science. Memiliki pengalaman dalam proyek berbasis data serta terbiasa mengubah kebutuhan bisnis menjadi insight yang dapat ditindaklanjuti melalui data dan teknologi. Saat ini antusias untuk terus mengembangkan keterampilan dalam analisa data, visualisasi, dan koordinasi proyek guna mendukung pengambilan keputusan berbasis data. Latar belakang akademik dan pengalaman proyek data mencerminkan komitmen saya untuk terus belajar dan berkembang di bidang data.



agilfirli29@gmail.com



www.linkedin.com/in/agil-firli-gunawan

Courses and Certification

- **Kickstart Data Science Journey - Rakamin Academy • Maret 2023**
- **Belajar Dasar Visualisasi Data – Dicoding Indonesia • September 2023**
- **Belajar Dasar Data Science – Dicoding Indonesia • September 2024**
- **Data Classification and Summarization Using IBM Granite – IBM • Juni 2025**
- **Data Fundamentals – IBM • Juni 2025**
- **Fundamental and Intermediate Data Science (Fresh Graduate Academy) – Digital Talent Scholarship • Agustus 2025**
- **Python Data Fundamentals – DataCamp • Agustus 2025**
- **AI Fundamentals Certification – DataCamp • Agustus 2025**

About Company

id/x partners berdiri sejak tahun 2002 oleh mantan banker dan konsultan manajemen dengan pengalaman luas dalam manajemen siklus dan proses kredit. Perusahaan ini beroperasi di berbagai sektor khususnya seperti jasa keuangan, telekomunikasi, manufaktur, dan ritel, serta telah melayani klien di kawasan Asia hingga Australia. layanan konsultasi yang berspesialisasi dalam pemanfaatan solusi analisis data dan pengambilan keputusan (DAD) yang dipadukan dengan manajemen risiko dan disiplin pemasaran terintegrasi untuk membantu klien mengoptimalkan profitabilitas portofolio dan proses bisnis. id/x partners membantu perusahaan mengoptimalkan profitabilitas portofolio serta efisiensi proses bisnis, sekaligus menawarkan layanan konsultasi dan solusi teknologi secara komprehensif.

Project Portfolio

Proyek ini bertujuan membangun model machine learning untuk memprediksi risiko kredit pada perusahaan multifinance. Risiko kredit muncul ketika peminjam gagal membayar pinjaman tepat waktu, yang dapat menimbulkan kerugian finansial, menurunkan profitabilitas, dan merugikan reputasi perusahaan.

Dataset yang digunakan adalah Loan Dataset dengan 466.285 baris dan 75 kolom, berisi informasi peminjam seperti jumlah pinjaman, tingkat bunga, pendapatan, dan status pinjaman (loan_status) sebagai target. Permasalahan utama adalah bagaimana memprediksi apakah calon peminjam berisiko tinggi atau rendah, sehingga perusahaan dapat mengurangi kerugian akibat gagal bayar, menjaga portofolio pinjaman tetap sehat, dan mendukung pengambilan keputusan berbasis data.

Link code github :

https://github.com/agilfirli29/Data-Science-Project-Credit-Risk-Prediction-Model-Using-Machine-Learning_.git

Link video presentasi :

<https://www.youtube.com/watch?v=BEVA1s09ol8>

Data Understanding

Mengidentifikasi Data

```
1 # Load dataset
2 df = pd.read_csv("loan_data.csv")
3 df.head(10)
```

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 466285 entries, 0 to 466284
Data columns (total 75 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Unnamed: 0            466285 non-null int64
1   id                    466285 non-null int64
2   member_id            466285 non-null int64
3   loan_amnt            466285 non-null int64
4   funded_amnt          466285 non-null int64
5   funded_amnt_inv      466285 non-null float64
```

Proses awal untuk memahami dataset yang digunakan. Dataset berisi 466.285 baris dengan 75 fitur yang terdiri dari data numerik dan kategorikal. Pada tahap ini dilakukan identifikasi data melalui `df.head()` untuk melihat sampel data serta `df.info()` untuk mengetahui struktur, tipe data, dan kelengkapan nilai. Variabel target yang akan diprediksi adalah `loan_status` dengan dua kategori, yaitu `Approved` dan `Default`.

Data Understanding

Eksplorasi awal

	count
loan_status	
Current	224226
Fully Paid	184739
Charged Off	42475
Late (31-120 days)	6900
In Grace Period	3146
Does not meet the credit policy. Status:Fully Paid	1988
Late (16-30 days)	1218
Default	832
Does not meet the credit policy. Status:Charged Off	761

dtype: int64

```
1 #Statistik Deskriptif
2 df.describe()
```

	Unnamed: 0	id	member_id	loan_amnt
count	466285.000000	4.662850e+05	4.662850e+05	466285.000000
mean	233142.000000	1.307973e+07	1.459766e+07	14317.277577
std	134605.029472	1.089371e+07	1.168237e+07	8286.509164
min	0.000000	5.473400e+04	7.047300e+04	500.000000
25%	116571.000000	3.639987e+06	4.379705e+06	8000.000000
50%	233142.000000	1.010790e+07	1.194108e+07	12000.000000
75%	349713.000000	2.073121e+07	2.300154e+07	20000.000000
max	466284.000000	3.809811e+07	4.086083e+07	35000.000000

Pada tahap eksplorasi awal, terlihat bahwa mayoritas pinjaman berstatus Current dan Fully Paid, sementara kategori seperti Default jumlahnya jauh lebih sedikit sehingga terjadi ketidakseimbangan kelas. Dari sisi numerik, misalnya loan_amnt, nilai pinjaman berkisar antara 500 hingga 35.000 dengan median sekitar 12.000, sehingga memberi gambaran awal karakteristik data.

Exploratory Data Analysis

Memahami distribusi tiap variabel

```
1 num_cols = ['loan_amnt', 'int_rate', 'annual_inc', 'dti']  
2 cat_cols = ['grade', 'home_ownership', 'purpose']
```


Pada tahap EDA, kita fokus menganalisis beberapa fitur utama diantara lain :

- Numerik: `loan_amnt`, `int_rate`, `annual_inc`, `dti` → menggambarkan jumlah pinjaman, suku bunga, pendapatan tahunan, dan rasio utang.
- Kategorikal: `grade`, `home_ownership`, `purpose` → menggambarkan peringkat kredit, kepemilikan rumah, dan tujuan pinjaman.

Hal ini dilakukan agar analisis lebih terarah pada faktor yang berhubungan dengan risiko kredit, sementara fitur lain akan dipertimbangkan pada tahap feature selection dan modeling.

Exploratory Data Analysis


Univariate Analysis



Univariate analysis dilakukan untuk memahami karakteristik setiap distribusi variabel secara terpisah. Dari hasil visualisasi, terlihat pada distribusi variabel numerik bahwa jumlah pinjaman umumnya berada di kisaran menengah, suku bunga terkonsentrasi pada 10–15%, dan pendapatan cenderung timpang dengan mayoritas di level rendah. Pada distribusi variabel kategorikal, mayoritas pinjaman berada di grade B dan C, sebagian besar peminjam berstatus mortgage atau rent, serta tujuan utama pinjaman adalah debt consolidation.

Exploratory Data Analysis


Bivariat Analysis



Bivariat analysis digunakan untuk melihat hubungan antara variabel independen dengan Loan Status, baik numerik (loan amount, interest rate, annual income, dti) maupun kategorikal (grade, home ownership, purpose). Hasilnya menunjukkan bahwa pinjaman dengan bunga lebih tinggi dan pendapatan lebih rendah cenderung gagal bayar. Sementara itu, pada variabel kategorikal terlihat bahwa grade kredit rendah (F-G), status rumah Mortgage/Rent, serta tujuan pinjaman debt consolidation lebih banyak dikaitkan dengan gagal bayar dibanding kelompok lain. Temuan ini memperlihatkan pola perbedaan antara pinjaman lunas dan gagal bayar sehingga memudahkan identifikasi faktor risiko utama.

Exploratory Data Analysis

Multivariate Analysis



Multivariate Analysis berupa korelasi antar variabel numerik. Terlihat `loan_amnt` berkorelasi sedang dengan `annual_inc` (0.37), menandakan pendapatan tinggi cenderung mengajukan pinjaman lebih besar. `Annual_inc` dengan `dti` berkorelasi negatif (-0.19), artinya semakin tinggi pendapatan maka rasio utang lebih rendah. Korelasi variabel lain lemah (<0.2), sehingga tidak ada multikolinearitas dan semua variabel tetap relevan untuk pemodelan.

Data Preparation

Menangani nilai yang hilang

```
1 print("Jumlah Missing Values sebelum ditangani:")
2 print(df.isnull().sum().sort_values(ascending=False).head(10))
3
4 # Imputasi contoh
5 df['emp_length'] = df['emp_length'].fillna(df['emp_length'].mode()[0]) # mode (kategorikal)
6 df['annual_inc'] = df['annual_inc'].fillna(df['annual_inc'].median()) # median (numerik)
7
8 # Drop kolom yang tidak relevan / terlalu banyak missing
9 df = df.drop(columns=['desc', 'url', 'member_id'], errors='ignore')
```

```
Jumlah Missing Values sebelum ditangani:
max_bal_bc      466285
open_rv_24m     466285
inq_fi          466285
open_rv_12m     466285
il_util         466285
mths_since_rcnt_il 466285
total_bal_il    466285
open_il_24m     466285
open_il_12m     466285
open_il_6m      466285
dtype: int64
```

```
1 df.isna().sum()
```

Unnamed: 0	0
id	0
loan_amnt	0
funded_amnt	0
funded_amnt_inv	0
...	...
all_util	466285
total_rev_hi_lim	70276
inq_fi	466285
total_cu_tl	466285
inq_last_12m	466285


72 rows × 1 columns
dtype: int64

Dilakukan pengecekan dan penanganan missing values. Variabel kategorikal seperti emp_length diimputasi dengan mode, sedangkan variabel numerik seperti annual_inc diimputasi dengan median. Kolom yang tidak relevan atau terlalu banyak missing values dihapus, sehingga dataset menjadi bersih dan siap untuk analisis maupun pemodelan.

Hasil dari df.isna().sum() pada slide menunjukkan bahwa setelah proses imputasi dan penghapusan kolom, seluruh nilai missing sudah tertangani. Tabel di sebelah kanan memperlihatkan semua kolom memiliki nilai 0 pada jumlah missing values, artinya dataset sudah bersih tanpa data yang hilang dan siap digunakan untuk tahap analisis berikutnya.

Data Preparation

Mengatasi Outlier



Untuk mengatasi outlier pada variabel `annual_inc` ditangani dengan metode winsorizing. Cara ini membatasi nilai ekstrem tanpa menghapus data, sehingga distribusi pendapatan tahunan menjadi lebih terkendali dan hasil analisis lebih stabil.

Melakukan encoding pada distribusi variabel kategorikal seperti `grade`, `home_ownership`, `purpose`, dan `verification_status`. Proses encoding mengubah data kategorikal menjadi bentuk numerik agar dapat diproses oleh algoritma machine learning. Misalnya, setiap kategori pada `grade` atau `purpose` direpresentasikan dengan angka tertentu. Model ini dapat memahami variabel kategorikal tanpa kehilangan informasi penting.

Melakukan Encoding

	grade	home_ownership	purpose	verification_status
0	1	5	1	2
1	2	5	0	1
2	2	5	11	0
3	2	5	9	1
4	1	5	9	1

Data Preparation

Melakukan Scalling atau Normalisasi

	count	mean	std	min	25%	50%	75%	max
loan_amnt	466285.0	1.170307e-17	1.000001	-1.667444	-0.762358	-0.279645	0.685781	2.495954
int_rate	466285.0	-1.142756e-15	1.000001	-1.929794	-0.651562	-0.038837	0.610606	2.806778
annual_inc	466285.0	9.472176e-16	1.000001	-1.346268	-0.683436	-0.229787	0.424300	4.331907
dti	466285.0	-1.848111e-16	1.000001	-2.193161	-0.746233	-0.044421	0.708338	2.900384

Scaling atau normalisasi dilakukan karena setiap fitur numerik memiliki skala berbeda, misalnya loan_amnt bernilai ribuan sementara int_rate hanya puluhan persen. Jika tidak dinormalisasi, model bisa bias terhadap variabel dengan nilai lebih besar. Setelah dilakukan scaling, hasil tabel menunjukkan nilai mean setiap variabel sudah mendekati 0 dan standar deviasi sekitar 1, sehingga semua fitur berada pada skala yang seimbang. Hal ini memastikan tidak ada variabel yang mendominasi perhitungan, membuat model lebih stabil dan akurat saat proses pemodelan.

Membagi data jadi Train set dan test set

Data kita dibagi menjadi dua bagian, yaitu train set dan test set. Train set terdiri dari sekitar 373 ribu data atau 80% dari total, sedangkan test set terdiri dari sekitar 93 ribu data atau 20% dari total. Train set ini digunakan untuk melatih model, sementara test set dipakai untuk mengevaluasi performa model agar kita tahu seberapa baik model bekerja pada data baru.

```

Shape data train: (373028, 71)
Shape data test : (93257, 71)

```

```

Persentase train set: 80.00%
Persentase test set : 20.00%

```


Feature Engineering

```
kolom high_dti:
      dti  high_dti
0  1.328632      0
1 -2.065791      0
2 -1.082491      0
3  0.354248      0
4  0.091865      0
```

```
kolom log_annual_inc:
      annual_inc  log_annual_inc
0  -1.212693      0.000000
1  -1.061477      0.000000
2  -1.346268      0.000000
3  -0.577585      0.000000
4   0.198660      0.181204
```

```
kolom loan_income_ratio:
      loan_amnt  annual_inc  loan_income_ratio
0  -1.124392    -1.212693      5.286449
1  -1.426088    -1.061477     23.197120
2  -1.438156    -1.346268      4.153305
3  -0.521001    -0.577585     -1.233386
4  -1.365749     0.198660     -1.139397
```

```
kolom short_emp:
      emp_length  emp_length_numeric  short_emp
0  10+ years      10.0                0
1   < 1 year       0.0                1
2  10+ years      10.0                0
3  10+ years      10.0                0
4    1 year        1.0                1
```

```
Kolom kategorikal: ['grade', 'home_ownership', 'purpose', 'verification_status']
Shape data setelah encoding: (466285, 99)
```

Feature engineering adalah proses mengolah data agar lebih informatif untuk model. Di sini kita menambah fitur baru seperti `high_dti`, `log_annual_inc`, `loan_income_ratio`, dan `short_emp`, serta melakukan encoding pada kolom kategorikal. Hasil akhirnya, data menjadi 466 ribu baris dengan 99 kolom

Data Modeling & Evalution

```
1 # Pilih subset fitur
2 num_cols = ['loan_amnt', 'int_rate', 'annual_inc', 'dti']
3 cat_cols = ['grade', 'home_ownership']
4 X = df_sample[num_cols + cat_cols]
```

```
1 # Split data
2 X_train, X_test, y_train, y_test = train_test_split(
3     X, y, test_size=0.2, random_state=42, stratify=y
4 )
5
```

```
# Inisialisasi model
models = {
    "Logistic Regression": LogisticRegression(max_iter=500, solver='liblinear'),
    "Random Forest": RandomForestClassifier(n_estimators=100, random_state=42),
    "XGBoost": XGBClassifier(use_label_encoder=False, eval_metric='logloss', random_state=42)
}
```

Di Tahap data modeling, kita memilih beberapa fitur penting baik numerik maupun kategorikal. Data kemudian dibagi menjadi train dan test set dengan rasio 80:20. Selanjutnya, kita menginisialisasi tiga model diantara lain :

- Logistic Regression, model yang sederhana tapi sering jadi baseline,
- Random Forest, model berbasis kumpulan pohon keputusan,
- dan XGBoost, model yang lebih canggih dan sering dipakai untuk kompetisi data science.

Data Modeling & Evalution

Logistic Regression Classification Report:

	precision	recall	f1-score	support
0	0.91	1.00	0.95	9091
1	0.00	0.00	0.00	909
accuracy			0.91	10000
macro avg	0.45	0.50	0.48	10000
weighted avg	0.83	0.91	0.87	10000

Random Forest Classification Report:

	precision	recall	f1-score	support
0	0.91	1.00	0.95	9091
1	0.27	0.01	0.03	909
accuracy			0.91	10000
macro avg	0.59	0.50	0.49	10000
weighted avg	0.85	0.91	0.87	10000

XGBoost Classification Report:

	precision	recall	f1-score	support
0	0.91	1.00	0.95	9091
1	0.24	0.01	0.01	909
accuracy			0.91	10000
macro avg	0.57	0.50	0.48	10000
weighted avg	0.85	0.91	0.87	10000

Pada hasil evaluasi, ketiga model menghasilkan akurasi yang sama, yaitu 91%, namun performanya berbeda pada kelas minoritas.

- Logistic Regression hanya mampu mengenali kelas mayoritas, sehingga kelas minoritas tidak terdeteksi sama sekali.
- Random Forest sedikit lebih baik, mampu mengenali sebagian kecil kelas minoritas dengan precision 0.27 meski recall masih sangat rendah.
- XGBoost juga serupa, memiliki precision 0.24 untuk kelas minoritas namun recall tetap rendah.

Kesimpulannya, meskipun akurasi terlihat tinggi, model masih belum optimal dalam menangani data yang tidak seimbang (imbalanced class).

Data Modeling & Evalution

```
=== Overfitting vs Underfitting ===
```

```
Logistic Regression - Train: 0.909, Test: 0.909
```


```
Random Forest - Train: 1.000, Test: 0.907
```

```
/usr/local/lib/python3.12/dist-packages/xgboost/training.py:183: UserWarning: [11:28:10] WARNING: /workspace/src/learner.cc:738:  
Parameters: { "use_label_encoder" } are not used.
```

```
bst.update(dtrain, iteration=i, fobj=obj)  
XGBoost - Train: 0.916, Test: 0.908
```

Kalau kita lihat hasil training dan testing, Logistic Regression punya skor train 0.909 dan test 0.909, artinya model ini cukup seimbang dan tidak overfitting. Random Forest justru terlihat overfitting, karena skor train 1.000 tapi test turun jadi 0.907. Artinya model belajar terlalu detail pada data latih tapi kurang generalisasi di data uji. Sedangkan XGBoost punya hasil train 0.916 dan test 0.908, perbedaannya kecil, sehingga model ini relatif seimbang dan cukup baik dalam generalisasi.

Data Modeling & Evalution




Grafik ini menunjukkan ROC Curve untuk membandingkan performa model.

Dari nilai AUC, terlihat bahwa:

- Logistic Regression memiliki AUC 0.53, mendekati garis random, sehingga performanya kurang baik.
- Random Forest sedikit lebih baik dengan AUC 0.63.
- XGBoost punya performa terbaik dengan AUC 0.65, walaupun masih relatif rendah.

Artinya, dari ketiga model, XGBoost adalah yang paling baik, tapi secara keseluruhan model masih perlu ditingkatkan.

Data Modeling & Evalution



Confusion Matrix ini memperlihatkan hasil prediksi dari setiap model.

- Logistic Regression hanya memprediksi kelas mayoritas (0) dan gagal mengenali kelas minoritas (1).
- Random Forest sudah mulai bisa mengenali kelas 1 dengan 12 prediksi benar, meskipun masih banyak salah klasifikasi.
- XGBoost sedikit lebih baik, mampu mengenali 6 data kelas 1 dengan kesalahan lebih sedikit dibanding Random Forest.

Kesimpulannya, meskipun Logistic Regression stabil di kelas mayoritas, Random Forest dan XGBoost lebih seimbang karena mulai bisa mendeteksi kelas minoritas."

Business Recommendation

Dari hasil percobaan prediction model, ternyata model XGBoost terbukti paling baik dibanding Logistic Regression dan Random Forest karena mampu memberi prediksi yang lebih akurat. Meski begitu, model ini masih kurang bagus dalam mengenali peminjam yang benar-benar berisiko. Karena itu, perusahaan disarankan tetap memakai XGBoost sebagai model utama, tapi dengan tambahan teknik seperti penyeimbangan data agar hasilnya lebih adil antara peminjam berisiko tinggi dan rendah. Model ini sebaiknya dipakai sebagai alat bantu keputusan, bukan pengganti penuh analisis kredit manual, serta perlu terus dipantau agar tetap sesuai dengan kondisi bisnis dan ekonomi yang berubah-ubah.

Conclusion

Proyek ini membuktikan bahwa machine learning bisa membantu perusahaan multifinance dalam menilai risiko kredit. Dari ketiga model yang dicoba, XGBoost adalah yang paling unggul dan direkomendasikan untuk dipakai sebagai sistem pendukung credit scoring. Dengan penerapan yang tepat, model ini bisa membantu perusahaan mengurangi risiko gagal bayar, menjaga portofolio pinjaman tetap sehat, dan membuat keputusan lebih tepat berdasarkan data.

Thank You

